Atividade 03

Guilherme Valverde Freiria 270535 Aluno 2 RA Aluno 3 RA

Exercício 1 Leia o enunciado do Exercício 1.6 do Weisberg. O conjunto de dados tem nome `Rateprof` e está disponível no pacote `alr4`.

```
##   gender numYears numRaters numCourses pepper discipline              dept
## 1   male        7        11          5     no        Hum           English
## 2   male        6        11          5     no        Hum Religious Studies
## 3   male       10        43          2     no        Hum               Art
## 4   male       11        24          5     no        Hum           English
## 5   male       11        19          7     no        Hum           Spanish
## 6   male       10        15          9     no        Hum           Spanish
##    quality helpfulness  clarity easiness raterInterest sdQuality sdHelpfulness
## 1 4.636364    4.636364 4.636364 4.818182      3.545455 0.5518564     0.6741999
## 2 4.318182    4.545455 4.090909 4.363636      4.000000 0.9020179     0.9341987
## 3 4.790698    4.720930 4.860465 4.604651      3.432432 0.4529343     0.6663898
## 4 4.250000    4.458333 4.041667 2.791667      3.181818 0.9325048     0.9315329
## 5 4.684211    4.684211 4.684211 4.473684      4.214286 0.6500112     0.8200699
## 6 4.233333    4.266667 4.200000 4.533333      3.916667 0.8632717     1.0327956
##   sdClarity sdEasiness sdRaterInterest
## 1 0.5045250  0.4045199       1.1281521
## 2 0.9438798  0.5045250       1.0744356
## 3 0.4129681  0.5407021       1.2369438
## 4 0.9990938  0.5882300       1.3322506
## 5 0.5823927  0.6117753       0.9749613
## 6 0.7745967  0.6399405       0.6685579
```

```
## 'data.frame':    366 obs. of  17 variables:
##  $ gender         : Factor w/ 2 levels "female","male": 2 2 2 2 2 2 2 2 2 2 ...
##  $ numYears       : int  7 6 10 11 11 10 7 11 11 7 ...
##  $ numRaters      : int  11 11 43 24 19 15 17 16 12 18 ...
##  $ numCourses     : int  5 5 2 5 7 9 3 3 4 4 ...
##  $ pepper         : Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
##  $ discipline     : Factor w/ 4 levels "Hum","SocSci",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ dept           : Factor w/ 48 levels "Accounting","Anthropology",..: 17 42 3 17 45 45 45 17 34 17
##  $ quality        : num  4.64 4.32 4.79 4.25 4.68 ...
##  $ helpfulness    : num  4.64 4.55 4.72 4.46 4.68 ...
##  $ clarity        : num  4.64 4.09 4.86 4.04 4.68 ...
##  $ easiness       : num  4.82 4.36 4.6 2.79 4.47 ...
##  $ raterInterest  : num  3.55 4 3.43 3.18 4.21 ...
##  $ sdQuality      : num  0.552 0.902 0.453 0.933 0.65 ...
##  $ sdHelpfulness  : num  0.674 0.934 0.666 0.932 0.82 ...
##  $ sdClarity      : num  0.505 0.944 0.413 0.999 0.582 ...
##  $ sdEasiness     : num  0.405 0.505 0.541 0.588 0.612 ...
##  $ sdRaterInterest: num  1.128 1.074 1.237 1.332 0.975 ...
```

```
##                 quality   clarity helpfulness  easiness raterInterest
## quality       1.0000000 0.9759608   0.9810314 0.5651154     0.4706688
## clarity       0.9759608 1.0000000   0.9208070 0.5358884     0.4611408
## helpfulness   0.9810314 0.9208070   1.0000000 0.5635184     0.4630321
## easiness      0.5651154 0.5358884   0.5635184 1.0000000     0.2052237
## raterInterest 0.4706688 0.4611408   0.4630321 0.2052237     1.0000000
```

Apresente abaixo um gráfico similar ao apresentado no enunciado. Comente sobre as relações entre as notas dos cinco quesitos avaliados.

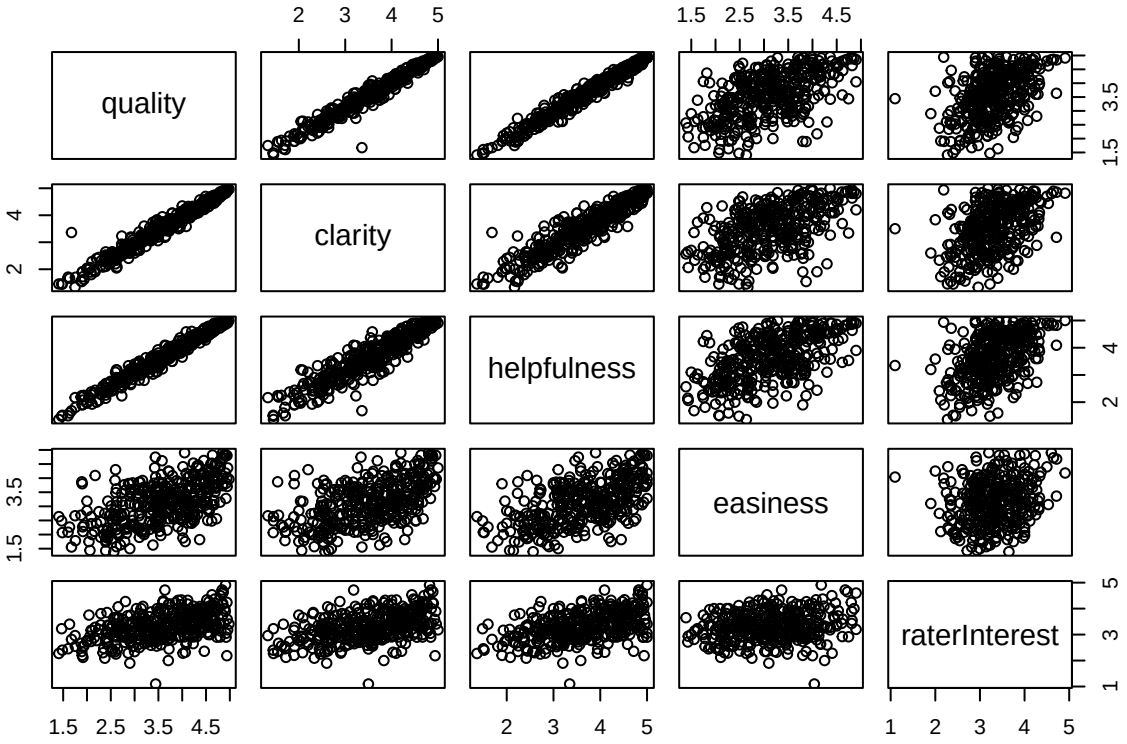

Analisando a matriz de gráficos de dispersão, observa-se que os pares quality e clarity, quality e helpfulness e clarity e helpfulness apresentam forte correlação positiva. Por outro lado, as variáveis easiness e raterInterest apresentam apenas correlação moderada, sendo menos associadas às demais variáveis, como quality, clarity e helpfulness.

Exercício 2 Considere o conjunto de dados `MA_schools` do pacote `moderndive`. Há interesse em predizer `average_sat_math` a partir da variável `perc_disadvan`.

```
## [1] "school_name"      "average_sat_math" "perc_disadvan"    "size"
```

A) Explique o que são as variáveis `average_sat_math` e `perc_disadvan`. Apresente estatísticas sumárias das duas variáveis de interesse, inclua o tamanho amostra. Apresente um diagrama de dispersão e use o mesmo para argumentar sobre uma regressão linear simples nos dados parecer ou não apropriada e qual seria o objetivo do modelo.

```
##  average_sat_math perc_disadvan
##  Min.   :336.0    Min.   : 3.10
##  1st Qu.:473.0    1st Qu.:11.78
##  Median :514.0    Median :22.00
##  Mean   :507.1    Mean   :26.70
##  3rd Qu.:540.0    3rd Qu.:38.40
##  Max.   :741.0    Max.   :83.30
```

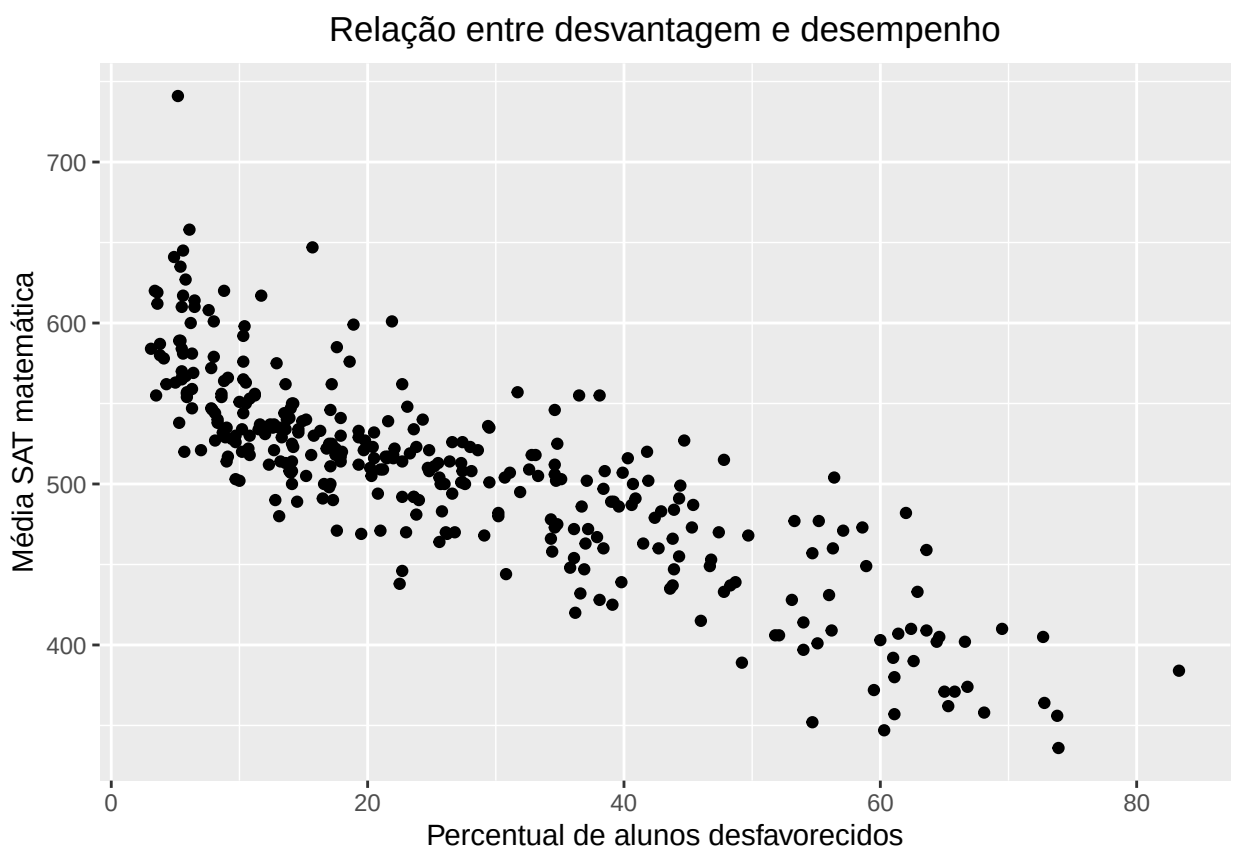

B) Calcule, usando o R, os valores de $\bar{x}$, $\bar{y}$, S_{XX}, S_{YY}, S_{XY}. Calcule as estimativas para β_0 e β_1 da regressão linear de Y em X usando os valores calculados. Apresente novamente o gráfico de dispersão, mas agora incluindo a reta ajustada.

```
# coloque os comandos para os cálculos
# nao usar a função lm aqui
```

```r
# usar echo=TRUE
# apague esses comentários antes de entregar

vet_x <- dados_df[["perc_disadvan"]]
vet_y <- dados_df[["average_sat_math"]]

x_barra <- mean(vet_x)
y_barra <- mean(vet_y)

sxx <- sum((vet_x - x_barra)^2)
syy <- sum((vet_y - y_barra)^2)
sxy <- sum((vet_x - x_barra)*(vet_y - y_barra))

b1 <-  sxy/sxx
b0 <- y_barra - b1*x_barra

vet_yi <- b0 + b1*vet_x

ggplot(dados_df, aes(x = perc_disadvan, y = average_sat_math)) +
  geom_point() +
  geom_abline(intercept = b0, slope = b1, color = 'red', size = 1)
```

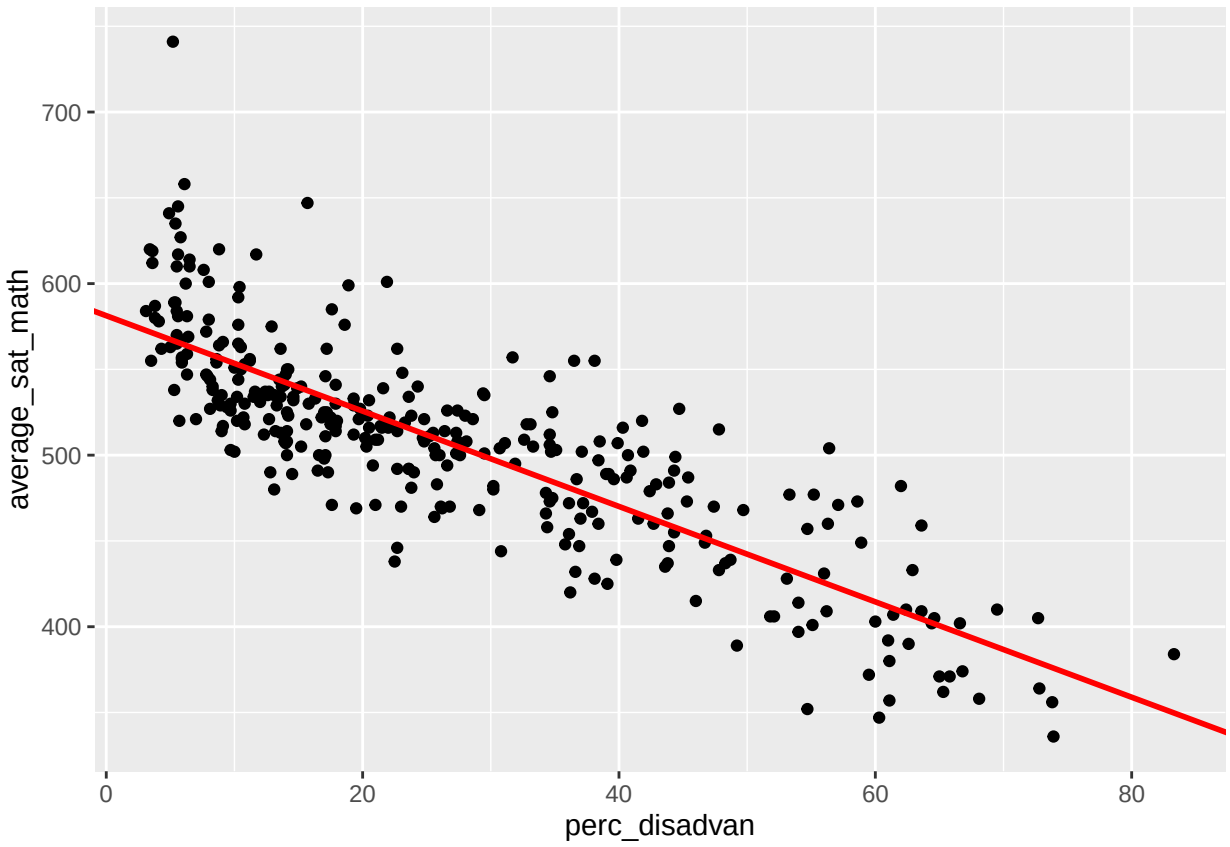


```r
  labs(
    title = "Relação entre desvantagem e desempenho",
    x = "Percentual de alunos desfavorecidos",
```

```
    y = "Média SAT matemática"
  )+
  theme(plot.title = element_text(hjust = 0.5))
```

```
## NULL
```

C) Calcule, usando o R, uma estimativa para σ^2 e encontre os erros padrões de $\hat{\beta}_0$ e $\hat{\beta}_1$. Calcule $\widehat{Cov}(\hat{\beta}_0, \hat{\beta}_1)$.

```
# coloque os comandos para os cálculos
# nao usar a função lm aqui
# usar echo=TRUE
# apague esses comentários antes de entregar

SQE <- sum((vet_y - vet_yi)^2)
s2 <- SQE/n-2

errop_b1 <- sqrt(s2/sxx)
errop_b0 <- sqrt(s2*((1/n) + (x_barra^2)/sxx))

covb0b1 <- (-s2)*(x_barra/sxx)
```

D) Calcule, usando o R, a estatística do teste para $H_0 : \beta_1 = 0$. Apresente o p-valor para o teste bilateral. Descreva e interprete o resultado em termos do problema.

E) Calcule, usando o R, um intervalo de confiança de 95% para β_1. Descreva e interprete o resultado em termos do problema.

F) Apresente os resultados usando as funções `lm`, `vcov` e `confint`.

Exercício 3 Alguns países exibem altas taxas de fertilidade, enquanto outros apresentam baixas taxas. Existe uma associação entre a taxa de fertilidade e a expectativa de vida? Utilize o conjunto de dados `un_member_states_2024` do pacote `moderndive` para avaliar esta possível associação. Para informações do conjunto de dados, use `?un_member_states_2024`.

A) Apresente estatísticas sumárias e gráficos adequados. Ao apresentar cada resultado, mencione o propósito, relacionando ao problema e aos próximos passos que você tomará na modelagem.

B) Ajuste um modelo de regressão linear simples adequado para o problema. Apresente as estimativas, erros-padrão, coeficiente de determinação e estimativa da variância do erro. Escreva uma ou duas sentenças que resumam os resultados encontrados com esses cálculos.

C) Apresente um intervalo de confiança para β_1 de 95%. Descreva e interprete o resultado em termos do problema.

D) Apresente um intervalo de confiança de 95% para a taxa de fertilidade média entre países em que a expectativa de vida é de 70 anos. Descreva e interprete o resultado em termos do problema.

E) Apresente um intervalo de predição de 95% para a taxa de fertilidade de um país em que a expectativa de vida é de 70 anos. Descreva e interprete o resultado em termos do problema.

Exercício 4 Em muitos problemas, o analista de dados pode focar no erro de predição médio de um modelo de regressão para descrever a acurácia esperada para predições futuras ou para ajudar na escolha entre modelos de regressão alternativos que podem ter sido ajustados aos dados. Quando temos um tamanho amostral suficiente, podemos usar a técnica de *validação cruzada*. A técnica consiste em dividirmos os dados em duas partes que podemos chamar de *treino* e *validação*. O subconjunto *treino* é utilizado para ajustar o modelo e obter as estimativas e o subconjunto *validação* é usado para testar a acurácia das predições.

A) Considere o conjunto de dados do **Exercício 2**. Selecione, ao acaso, aproximadamente 2/3 dos dados para o *treino* (use o comando `set.seed`). O 1/3 restante serão o subconjunto *validação*. Considerando apenas o subconjunto *treino*, ajuste um modelo de regressão.

B) Considerando o modelo de regressão ajustado, obtenha predições para a variável resposta usando os valores dos preditores do subconjunto *validação*. Calcule a média dos quadrados dos resíduos. A raíz quadrada deste valor é conhecida como *RMSE* (*root mean square error*).

Compare *RMSE* do subconjunto *validação* com o *RMSE* do subconjunto *treino*.